

Course Six

Google Advanced Data Analytics Capstone



Instructions

Use this PACE strategy document to record your decisions and reflections as a data professional as you work through the capstone project. As a reminder, this document is a resource guide that you can reference in the future and a space to help guide your responses and reflections posed at various points throughout the project.

Portfolio Project Recap

Many of the goals you accomplished in your individual course portfolio projects are incorporated into the Advanced Data Analytics capstone project including:

- Create a project proposal
- Demonstrate understanding of the form and function of Python
- Show how data professionals leverage Python to load, explore, extract, and organize information through custom functions
- Demonstrate understanding of how to organize and analyze a dataset to find the “story”
- Create a Jupyter notebook for exploratory data analysis (EDA)
- Create visualization(s) using Tableau
- Use Python to compute descriptive statistics and conduct a hypothesis test
- Build a multiple linear regression model with ANOVA testing
- Evaluate the model
- Demonstrate the ability to use a notebook environment to create a series of machine learning models on a dataset to solve a problem
- Articulate findings in an executive summary for external stakeholders



Proposta de Projeto

Salifort Motors: proposta de projeto

Resumo

A empresa Salifort Motors está procurando um método para estimar o que faz um funcionário deixar a empresa baseado em alguns de seus dados.

Milestones	Objetivos	Estratégias PACE
1	Entender o contexto do cenário e definir o problema	Planejamento
2	Exploração e limpeza de dados	Planejamento, Análise
3	Determinar modelo mais apropriado	Análise, Construção
4	Construir modelo	Construção
5	Confirmar as suposições do modelo	Análise, Construção
6	Avaliar resultados do modelo	Análise
7	Interpretar e compartilhar resultado com stakeholders	Execução

Questões e perguntas do Projeto de Dados



PACE: Estágio de Planejamento

O principal objetivo deste projeto é desenvolver um modelo preditivo para a Salifort Motors que identifique a probabilidade de um funcionário deixar a empresa. Atualmente, a empresa enfrenta uma alta taxa de rotatividade (turnover) que gera custos financeiros significativos relacionados a recrutamento e treinamento. **Sendo assim, nosso público-alvo (stakeholders) é a equipe de liderança sênior e o departamento de Recursos Humanos, que utilizarão os insights dessa análise para desenvolver estratégias práticas de retenção.**

Para realizar essa tarefa, os recursos utilizados incluem a linguagem Python e o conjunto de dados HR_capstone_dataset.csv, que contém 14.999 linhas e 10 colunas com informações autorrelatadas pelos colaboradores. A variável mais relevante e que servirá como nosso alvo (target) é a coluna left, que indica se o funcionário já saiu da empresa. Minha presunção inicial é que fatores como satisfaction_level, average_monthly_hours e number_project terão uma forte correlação com o esgotamento (burnout) e a decisão de saída, hipótese que será validada durante a Análise Exploratória de Dados (EDA).

Nesta fase de planejamento, é crucial considerar que estamos lidando com dados sensíveis de RH, exigindo responsabilidade ética na manipulação e garantia de privacidade dos funcionários. Além disso, confiamos que a amostra fornecida é aleatória e representativa de todos os setores; caso contrário, um viés de amostragem poderia comprometer a eficácia do modelo para departamentos específicos. **O produto final (deliverable) será a construção e avaliação de modelos de Regressão Logística ou outro tipo de ML, consolidados em um Sumário Executivo que traduzirá os resultados técnicos em recomendações de negócios claras.**



Questões e perguntas do Projeto de Dados



PACE: Estágio de Análise

Nesta fase de Análise, o foco principal é realizar uma Análise Exploratória de Dados (EDA) rigorosa para confirmar se as informações disponíveis são suficientes para atingir nosso objetivo preditivo. As estatísticas descritivas são fundamentais aqui para entendermos a distribuição inicial dos dados, identificando médias e identificando possíveis *outliers* (como extremos em horas trabalhadas ou níveis de satisfação muito baixos). A estruturação inicial do conjunto de dados envolverá a renomeação de colunas para padronização, a verificação de valores nulos e a remoção de linhas duplicadas para garantir a integridade das informações antes da modelagem.

Para traduzir esses dados em insights compreensíveis para a liderança, a aposta será em visualizações claras e diretas. Utilizaremos heatmaps para identificar a correlação entre as variáveis independentes e a variável alvo, além de gráficos de barras e boxplots para comparar a taxa de rotatividade entre diferentes departamentos e níveis salariais. Esses passos da EDA são cruciais antes de construir os modelos, pois permitem verificar premissas matemáticas importantes, como a ausência de alta multicolinearidade — um requisito essencial caso optemos por avançar com a Regressão Logística.

Por fim, a seleção das variáveis preditoras será baseada diretamente no que a EDA nos revelar sobre sua influência na saída dos funcionários. **Durante todo esse processo de exploração e limpeza estrutural, manteremos considerações éticas em mente, garantindo que as conclusões tiradas não reforcem vieses injustos e que os dados autorrelatados continuem descaracterizados para proteger a privacidade dos colaboradores.** Confirmada a confiabilidade dos dados e validadas as premissas, o plano original de seguir com a construção dos modelos de *Machine Learning* e estatística se mantém sólido.



Questões e perguntas do Projeto de Dados



PACe: Estágio de Construção

Para atingir os objetivos preditivos do projeto, esta fase foca na engenharia de recursos e na construção dos modelos de *Machine Learning* e estatística, especificamente **Regressão Logística, Random Forest e XGBoost**. O processo de preparação exige a codificação de variáveis categóricas (como `department` e `salary`) em formato numérico (variáveis *dummy*) e o tratamento de anomalias descobertas na fase de análise, como valores extremos de horas trabalhadas ou inconsistências em avaliações. As variáveis independentes (X) escolhidas para alimentar os modelos englobarão os atributos que demonstraram maior poder preditivo na EDA, como o nível de satisfação (`satisfaction_level`), a carga de trabalho (`average_monthly_hours`) e o número de projetos (`number_project`).

A validação de como o modelo se ajusta aos dados não se baseará apenas na acurácia global, mas principalmente em métricas mais sensíveis ao desbalanceamento de classes, como **Precision, Recall, F1-score e a curva ROC-AUC**. Caso as métricas iniciais de validação revelem um ajuste insatisfatório (como *overfitting* nas árvores de decisão), o modelo será aprimorado através do ajuste de hiperparâmetros (usando técnicas como *GridSearchCV*). Além disso, visualizações como matrizes de confusão e gráficos de importância de recursos (*feature importance*) serão geradas para interpretar como o modelo toma suas decisões.

Do ponto de vista ético, o principal cuidado nesta etapa é garantir que o algoritmo não desenvolva vieses discriminatórios. Precisamos observar se o modelo penaliza injustamente ou prevê taxas de evasão distorcidas para grupos salariais mais baixos ou departamentos específicos de forma não justificada. O objetivo da construção desse modelo é ajudar a empresa a intervir positivamente e melhorar a cultura do ambiente de trabalho, e não criar uma ferramenta de monitoramento punitiva.

Questões e perguntas do Projeto de Dados



PACE: Estágio de Execução

Nesta etapa final, traduzimos o desempenho técnico dos modelos em recomendações de negócios estratégicas para a equipe de liderança. A avaliação dos modelos demonstrou que algoritmos baseados em árvores (*Random Forest* ou *XGBoost*) superam a Regressão Logística em capacidade preditiva geral. No entanto, a análise estatística inicial da Regressão Logística provou ser valiosa: ao interpretar os coeficientes beta, pudemos entender a direção exata e a magnitude do impacto de cada variável. **Os principais *insights* indicam que o excesso de trabalho (altos valores em *average_monthly_hours* e *number_project*) associado a baixos níveis de satisfação (*satisfaction_level*) são os maiores impulsionadores da rotatividade. Funcionários sobrecarregados estão esgotados, enquanto aqueles com pouquíssimos projetos também saem, possivelmente por desmotivação.**

Com base nesses resultados, a principal recomendação de negócios para aumentar a retenção é limitar a quantidade simultânea de projetos por funcionário e monitorar de perto a carga horária mensal, evitando o *burnout*. Além disso, a empresa deve revisar sua estrutura de incentivos e promoções, já que a ausência de progressão na carreira também afeta negativamente a permanência. Para compartilhar essas informações de forma eficaz, os gráficos de importância de recursos (*feature importance*) e a matriz de confusão serão simplificados e incluídos no Sumário Executivo, garantindo que públicos não técnicos consigam compreender claramente as causas do problema e o valor do modelo preditivo.

Do ponto de vista ético e de implementação, é essencial entender o impacto das falhas do modelo. Quando o algoritmo comete um erro (como um Falso Positivo), a empresa pode acabar direcionando esforços de retenção para um funcionário que não pretendia sair; por outro lado (Falso Negativo), a empresa pode perder um talento que o modelo julgou estar seguro. Eticamente, os resultados deste modelo devem ser usados de forma proativa para apoiar os colaboradores e melhorar a cultura da empresa, e não como uma ferramenta de vigilância ou base para demissões preventivas. No futuro, para fortalecer ainda mais esse modelo, a equipe poderia investigar a adição de novos dados, como distância de deslocamento para o trabalho, formato de trabalho (remoto/presencial) e histórico de bônus financeiros.